

## Função de Rosenbrock - Otimização e Buscas

### Introdução

O presente relatório consiste em apresentar os resultados obtidos através das análises de otimização feitas utilizando a função de Rosenbrock. Para estudar a função e gerar os gráficos, usou-se a linguagem de programação Python junto com diversas bibliotecas. Os resultados foram obtidos através de uma busca sequencial e dez buscas aleatórias.

### A Função de Rosenbrock

A função também é conhecida como função banana ou vale, de n-dimensões e é bem conhecida por ser utilizada em algoritmos de otimização baseados em gradiente. Possui o mínimo global em um vale parabólico, fácil de ser encontrado, porém de difícil convergência. A função é apresentada da seguinte forma:


$$f(\mathbf{x}) = \sum_{i=1}^{d-1} [100(x_{i+1} - x_i^2)^2 + (x_i - 1)^2]$$

O seu mínimo global é:

$$f(\mathbf{x}^*) = 0, \text{ at } \mathbf{x}^* = (1, \dots, 1)$$

A função de Rosenbrock pode ser analisada em dois intervalos distintos,  $x_i \in [-5, 10]$  e  $x_i \in [-2.048, 2.048]$ , para todo  $i = 1, \dots, d$ .

O gráfico da função é desta forma:



## Algoritmos

Os algoritmos usados para o estudo foram fornecidos previamente e era preciso adaptá-los para gerar os resultados buscados. A função de Rosenbrock foi representada em Python em *rosenbrock(args)*, sendo *args* os parâmetros referentes às variáveis das dimensões adotadas. Para gerar os gráficos, adotou-se duas dimensões e por isso, x e y.

```
import random
import matplotlib.pyplot as plt
import numpy as np

import plotly.graph_objects as go
#função para iterar com um passo decimal
def drange(start, stop, step):
    r = start
    while r < stop:
        yield r
        r += step
def funcao_objetivo(x):
    return (x-10)**2+1
def funcao_objetivo_seno(x):
    return np.sin(x)
def rosenbrock(args):
    x,y=args
    return (1 - x)**2 + 100*(y - x**2)**2
```

A busca sequencial consiste em buscar os melhores valores dentro dos intervalos fornecidos e pelo tamanho do passo. Para duas dimensões, inclui-se x e y para buscar seus melhores valores.

```
def busca_sequencial(tamanho_passo, limite_inferior, limite_superior):
    melhor_x=None
    melhor_y=None
    melhor_valor = np.inf

    melhores_dominios=[]
    melhores_imagens =[]
    dominio_x=[]
    dominio_y=[]
    imagem=[]

    for x in drange(limite_inferior,limite_superior+tamanho_passo,
tamanho_passo):
        for y in drange(limite_inferior, limite_superior +
tamanho_passo, tamanho_passo):
            valor = rosenbrock((x,y))
```

```

        if melhor_valor > valor:
            melhor_valor = valor
            melhor_x=x
            melhor_y=y

    melhores_dominios.append((melhor_x, melhor_y))
    melhores_imagens.append(melhor_valor)
    dominio_x.append(x)
    dominio_y.append(y)
    imagem.append(valor)

    return melhor_x,melhor_y,melhor_valor,dominio_x,dominio_y, imagem,
    melhores_dominios, melhores_imagens

```

Já a busca aleatória procura encontrar os melhores valores de forma aleatória, ou seja, as variáveis adotam um valor qualquer dentro do intervalo (chute inicial) e depois é decidido se aquele valor é melhor do que a encontrada anteriormente.

```

def busca_aleatoria(quantidade_iteracoes, limite_inferior,
limite_superior):
    melhor_x=None
    melhor_y=None
    melhor_valor = np.inf
    # melhor_z=None

    melhores_dominios=[]
    # melhores_dominiosZ=[]
    melhores_imagens =[]
    dominio_x=[]
    dominio_y=[]
    # dominioZ=[]
    imagem=[]

    for _ in range(quantidade_iteracoes):
        x=random.uniform(limite_inferior,limite_superior)
        y=random.uniform(limite_inferior,limite_superior)
        valor = rosenbrock((x,y))
        # z=random.uniform(limite_inferior,limite_superior)
        # y= ackley(x,z)
        # y=funcao_objetivo(x)
        if melhor_valor > valor:
            melhor_valor = valor
            melhor_x = x

```

```

        melhor_y = y

    melhores_dominios.append((melhor_x, melhor_y))
    # melhores_dominiosZ.append(melhor_z)
    melhores_imagens.append(melhor_valor)

    dominio_x.append(x)
    dominio_y.append(y)
    # dominioZ.append(z)
    imagem.append(valor)

    # return melhor_x,melhor_z,melhor_y, dominio,dominioZ, imagem,
    melhores_dominios,melhores_dominiosZ, melhores_imagens
    return melhor_x,melhor_y, melhor_valor,dominio_x,dominio_y, imagem,
    melhores_dominios, melhores_imagens

```

## Resultados para 2 dimensões

O código abaixo realiza 10 buscas aleatórias independentes para encontrar os melhores valores, piores, média, mediana e desvio padrão. A cada vez que roda o código inteiro, valores diferentes são encontrados e portanto os resultados sempre serão distintos. Como a função de Rosenbrock apresenta duas formas de restringir o domínio (*limite\_inferior* e *limite\_superior*), duas tabelas de resultados serão apresentadas.

```

import time
import numpy as np
import pandas as pd

# Parâmetros
quantidade_iteracoes = 60
limite_inferior = -5
limite_superior = 10
num_execucoes = 10

# Listas para armazenar os melhores valores e tempos de cada execução
melhores_valores = []
tempos_execucao = []

for i in range(num_execucoes):
    # Medir o tempo de execução
    inicio_tempo = time.time()

    # Executar a busca aleatória
    x, y, melhor_valor, dominio_x, dominio_y, imagem,
    melhores_dominios, melhores_imagens = busca_aleatoria(
        quantidade_iteracoes, limite_inferior, limite_superior

```

```

)

# Calcular o tempo de execução
tempo_execucao = time.time() - inicio_tempo

# Armazenar o melhor valor e o tempo da execução atual
melhores_valores.append(melhor_valor)
tempos_execucao.append(tempo_execucao)
print(f"Execução {i+1}: Melhor valor = {melhor_valor}, Tempo = {tempo_execucao:.4f} segundos")

# Cálculo das estatísticas dos melhores valores
melhor_resultado = np.min(melhores_valores)
pior_resultado = np.max(melhores_valores)
media_resultado = np.mean(melhores_valores)
mediana_resultado = np.median(melhores_valores)
desvio_padrao_resultado = np.std(melhores_valores)

# Cálculo das estatísticas de tempo
tempo_medio = np.mean(tempos_execucao)
tempo_mediana = np.median(tempos_execucao)
tempo_desvio_padrao = np.std(tempos_execucao)

# Criar DataFrame com os resultados de cada execução
df_execucoes = pd.DataFrame({
    'Execução': list(range(1, num_execucoes + 1)),
    'Melhor Valor': melhores_valores,
    'Tempo de Execução (s)': tempos_execucao
})

# Adicionar uma linha final com as estatísticas agregadas em colunas separadas
df_estatisticas = pd.DataFrame({
    'Execução': ['Estatísticas'],
    'Melhor Valor': [melhor_resultado],
    'Tempo de Execução (s)': [np.nan], # Deixar em branco para o tempo
    'Pior Valor': [pior_resultado],
    'Média dos Valores': [media_resultado],
    'Mediana dos Valores': [mediana_resultado],
    'Desvio Padrão dos Valores': [desvio_padrao_resultado],
    'Tempo Médio (s)': [tempo_medio],
    'Tempo Mediana (s)': [tempo_mediana],
})

```

```

    'Tempo Desvio Padrão (s)': [tempo_desvio_padrao]
}))

# Concatenar os DataFrames, alinhando as colunas
df_final = pd.concat([df_execucoes, df_estatisticas],
ignore_index=True)

# Exibir a tabela completa com preenchimento de NaNs
print("\nResultados das Execuções Individuais e Estatísticas
Agregadas:")
print(df_final.fillna('N/A'))

```

Para o domínio de [-5,10], os seguintes resultados foram encontrados:

Execução 1: Melhor valor = 24.354362277290704, Tempo = 0.0010 segundos  
 Execução 2: Melhor valor = 14.854363416635527, Tempo = 0.0000 segundos  
 Execução 3: Melhor valor = 32.814013923323806, Tempo = 0.0000 segundos  
 Execução 4: Melhor valor = 11.800025166081133, Tempo = 0.0000 segundos  
 Execução 5: Melhor valor = 19.654467147579304, Tempo = 0.0000 segundos  
 Execução 6: Melhor valor = 34.01605676268375, Tempo = 0.0000 segundos  
 Execução 7: Melhor valor = 24.70922220829673, Tempo = 0.0000 segundos  
 Execução 8: Melhor valor = 43.061149611280506, Tempo = 0.0000 segundos  
 Execução 9: Melhor valor = 8.418098977704012, Tempo = 0.0015 segundos  
 Execução 10: Melhor valor = 20.38677153103563, Tempo = 0.0000 segundos

Resultados das Execuções Individuais e Estatísticas Agregadas:

	Execução	Melhor Valor	Tempo de Execução (s)	Pior Valor \
0	1	24.354362	0.000987	N/A
1	2	14.854363	0.0	N/A
2	3	32.814014	0.0	N/A
3	4	11.800025	0.0	N/A
4	5	19.654467	0.0	N/A
5	6	34.016057	0.0	N/A
6	7	24.709222	0.0	N/A
7	8	43.061150	0.0	N/A
8	9	8.418099	0.00151	N/A
9	10	20.386772	0.0	N/A
10	Estatísticas	8.418099	N/A	43.06115

	Média dos Valores	Mediana dos Valores	Desvio Padrão dos Valores \
0	N/A	N/A	N/A
1	N/A	N/A	N/A
2	N/A	N/A	N/A
3	N/A	N/A	N/A
4	N/A	N/A	N/A
5	N/A	N/A	N/A
6	N/A	N/A	N/A
7	N/A	N/A	N/A
8	N/A	N/A	N/A
9	N/A	N/A	N/A

10	23.406853	22.370567	10.225765
----	-----------	-----------	-----------

	Tempo Médio (s)	Tempo Mediana (s)	Tempo Desvio Padrão (s)
0	N/A	N/A	N/A
1	N/A	N/A	N/A
2	N/A	N/A	N/A
3	N/A	N/A	N/A
4	N/A	N/A	N/A
5	N/A	N/A	N/A
6	N/A	N/A	N/A
7	N/A	N/A	N/A
8	N/A	N/A	N/A
9	N/A	N/A	N/A
10	0.00025	0.0	0.000513

Para o domínio [-2.048,2.048], os seguintes resultados foram encontrados:

Execução 1: Melhor valor = 0.12294738824162921, Tempo = 0.0000 segundos  
 Execução 2: Melhor valor = 1.1748602082881057, Tempo = 0.0000 segundos  
 Execução 3: Melhor valor = 1.8560791888466237, Tempo = 0.0000 segundos  
 Execução 4: Melhor valor = 2.331296833475802, Tempo = 0.0000 segundos  
 Execução 5: Melhor valor = 1.7234005261226213, Tempo = 0.0010 segundos  
 Execução 6: Melhor valor = 0.1269732432517869, Tempo = 0.0000 segundos  
 Execução 7: Melhor valor = 0.1573412493876463, Tempo = 0.0000 segundos  
 Execução 8: Melhor valor = 0.537477647047272, Tempo = 0.0000 segundos  
 Execução 9: Melhor valor = 0.6185216536059633, Tempo = 0.0000 segundos  
 Execução 10: Melhor valor = 0.8965965118285681, Tempo = 0.0000 segundos

Resultados das Execuções Individuais e Estatísticas Agregadas:

	Execução	Melhor Valor	Tempo de Execução (s)	Pior Valor \
0	1	0.122947	0.0	N/A
1	2	1.174860	0.0	N/A
2	3	1.856079	0.0	N/A
3	4	2.331297	0.0	N/A
4	5	1.723401	0.000994	N/A
5	6	0.126973	0.0	N/A
6	7	0.157341	0.0	N/A
7	8	0.537478	0.0	N/A
8	9	0.618522	0.0	N/A
9	10	0.896597	0.0	N/A
10	Estatísticas	0.122947	N/A	2.331297

	Média dos Valores	Mediana dos Valores	Desvio Padrão dos Valores \
0	N/A	N/A	N/A
1	N/A	N/A	N/A
2	N/A	N/A	N/A
3	N/A	N/A	N/A
4	N/A	N/A	N/A
5	N/A	N/A	N/A
6	N/A	N/A	N/A
7	N/A	N/A	N/A
8	N/A	N/A	N/A

9	N/A	N/A	N/A
10	0.954549	0.757559	0.751669

	Tempo Médio (s)	Tempo Mediana (s)	Tempo Desvio Padrão (s)
0	N/A	N/A	N/A
1	N/A	N/A	N/A
2	N/A	N/A	N/A
3	N/A	N/A	N/A
4	N/A	N/A	N/A
5	N/A	N/A	N/A
6	N/A	N/A	N/A
7	N/A	N/A	N/A
8	N/A	N/A	N/A
9	N/A	N/A	N/A
10	0.000099	0.0	0.000298

Para a geração dos gráficos, também levou em consideração os domínios distintos. Para fins de visualização, adotou-se 10 pontos e 500 pontos.


```
#Dados para plot do gráfico 3D
fig = plt.figure()
ax = fig.add_subplot(projection='3d')

x1_v = np.linspace(-2.048,2.048,500)
x2_v = np.linspace(-2.048,2.048,500)
x1_arr, x2_arr = np.meshgrid(x1_v,x2_v)

f_arr = [[rosenbrock([x1_,x2_]) for x1_ in x1_v] for x2_ in x2_v]
f_arr = np.array(f_arr)

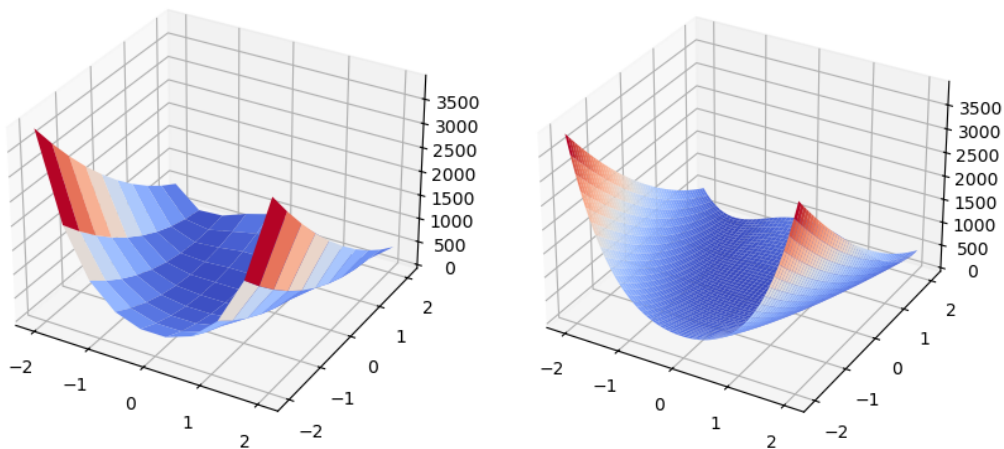
# ax=plt.figure().add_subplot(projection='3d')
surf =ax.plot_surface(x1_arr,x2_arr,f_arr,cmap=plt.cm.coolwarm)
```

Domínio [-5,10]:





Domínio [-2.048,2.048]:



A busca exaustiva encontra o mínimo da função dentro de um determinado intervalo. Para fins de teste, a função de Rosenbrock também foi verificada no código com os dois domínios. Foram gerados gráficos de níveis e lineares (y fixo em 1).

```
def funcao_rosenbrock(x, y, a=1, b=100):  
    """  
    Função de Rosenbrock.  
  
    Parâmetros:  
    x (float): Ponto no eixo x.  
    y (float): Ponto no eixo y.  
    a (float): Parâmetro da função de Rosenbrock (padrão é 1).  
    b (float): Parâmetro da função de Rosenbrock (padrão é 100).  
  
    Retorna:  
    float: Valor da função de Rosenbrock para os pontos (x, y).  
    """  
    return (a - x)**2 + b * (y - x**2)**2  
  
def busca_exaustiva(a, b, passos):  
    """  
    Realiza uma busca exaustiva para encontrar o mínimo de uma função f  
    no intervalo [a, b].  
  
    Parâmetros:  
    f (callable): Função a ser minimizada.  
    a (float): Limite inferior do intervalo.  
    b (float): Limite superior do intervalo.  
    passos (int): Número de pontos a serem avaliados no intervalo.
```

```

Retorna:
float: Ponto onde a função f tem o menor valor.
float: Valor mínimo da função.
"""

# Cria um vetor de pontos uniformemente espaçados no intervalo [a,
b]
x = np.linspace(a, b, passos)
y = np.linspace(a, b, passos)
x_grid, y_grid = np.meshgrid(x, y)

# Avalia a função em cada ponto
valores = funcao_rosenbrock(x_grid, y_grid)

# Encontra o índice do valor mínimo
idx_min = np.unravel_index(np.argmin(valores), valores.shape)
ponto_minimo_x = x_grid[idx_min]
ponto_minimo_y = y_grid[idx_min]
valor_minimo = valores[idx_min]

# Retorna o ponto de mínimo e o valor mínimo
return (ponto_minimo_x, ponto_minimo_y), valor_minimo, x_grid,
y_grid, valores

# Exemplo de uso
# Definindo uma função exemplo  $f(x) = (x - 2)^2$ 

# Intervalo de busca [a, b] e número de passos
limite_inferior = -5
limite_superior = 10
passos = 1000

# Encontrando o mínimo
ponto_minimo, valor_minimo, x_grid, y_grid, valores = busca_exaustiva(
    limite_inferior, limite_superior, passos
)

# Plotando a função e o ponto de mínimo
plt.figure(figsize=(8, 6))
plt.contourf(x_grid, y_grid, valores, levels=50, cmap='viridis')
plt.colorbar(label='Valor da função de Rosenbrock')

```

```

plt.scatter(*ponto_minimo, color='red', label=f'Mínimo em (x, y) =
({ponto_minimo[0]:.2f}, {ponto_minimo[1]:.2f})')
plt.title('Busca Exaustiva do Mínimo da Função de Rosenbrock')
plt.xlabel('x')
plt.ylabel('y')
plt.legend()
plt.show()

print(f'O mínimo da função ocorre em (x, y) = {ponto_minimo}')
print(f'O valor mínimo da função é f(x, y) = {valor_minimo}')

# Criação dos pontos no eixo x e avaliação da função com y fixo
x = np.linspace(limite_inferior, limite_superior, passos)
valores = funcao_rosenbrock(x, y=1) # Mantendo y fixo em 1

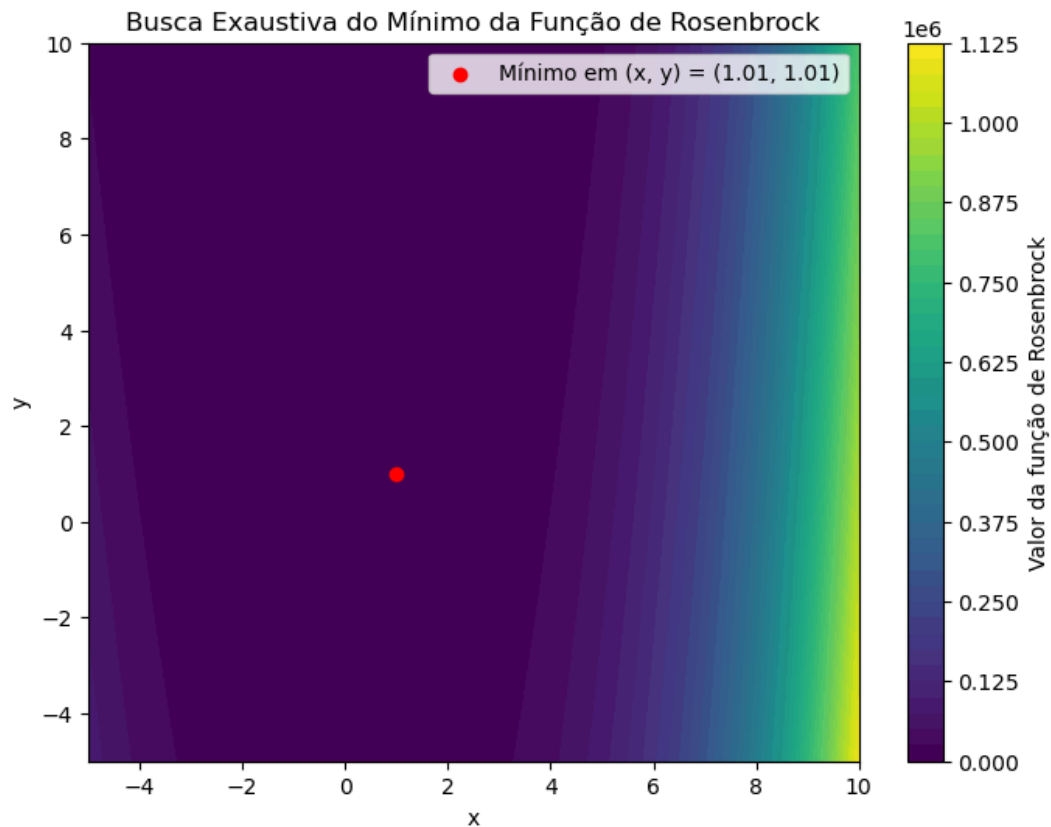
# Encontrando o índice do valor mínimo
idx_min = np.argmin(valores)
ponto_minimo_x = x[idx_min]
valor_minimo = valores[idx_min]

# Plotando o gráfico linear
plt.figure(figsize=(8, 5))
plt.plot(x, valores, label='f(x, y=1)', color='blue')
plt.scatter(ponto_minimo_x, valor_minimo, color='red', label=f'Mínimo
em x = {ponto_minimo_x:.2f}', zorder=5)
plt.title('Função de Rosenbrock ao longo de x com y fixo (Gráfico
Linear)')
plt.xlabel('x')
plt.ylabel('f(x, y=1)')
plt.grid(True)
plt.legend()
plt.show()


print(f'O mínimo da função ocorre em x = {ponto_minimo_x}')
print(f'O valor mínimo da função é f(x, y=1) = {valor_minimo}')

```

Pelo domínio [-5,10], encontrou-se os seguintes resultados:

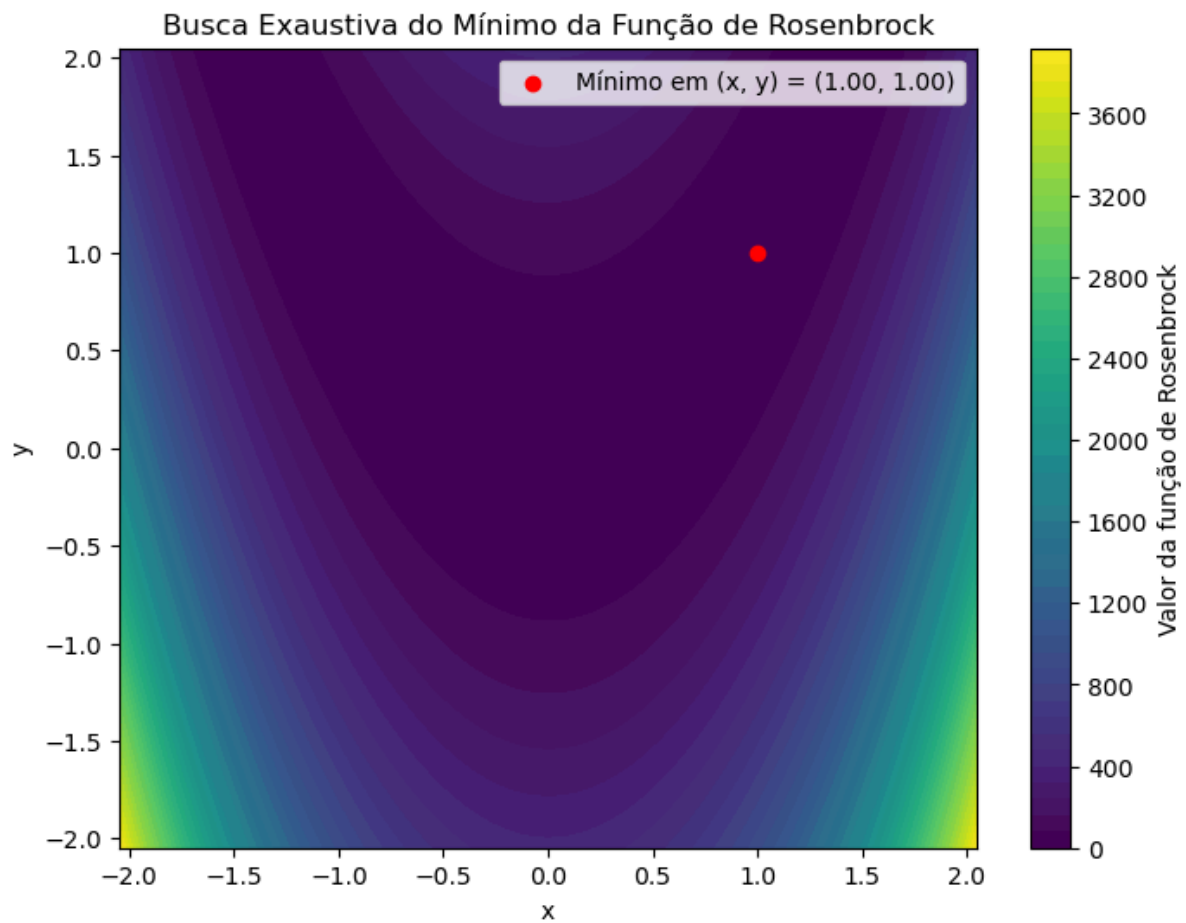


O mínimo da função ocorre em  $(x, y) = (1.0060060060060056, 1.0060060060060056)$   
 O valor mínimo da função é  $f(x, y) = 0.003686742901893119$




O mínimo da função ocorre em  $x = 1.0060060060060056$   
O valor mínimo da função é  $f(x, y) = 0.014551705204778649$

Para o domínio  $[-2.048, 2.048]$ , os seguintes resultados foram encontrados:



O mínimo da função ocorre em  $(x, y) = (0.9983743743743743, 0.9983743743743743)$   
O valor mínimo da função é  $f(x, y) = 0.00026605002977602083$



O mínimo da função ocorre em  $x = 0.9983743743743743$

O valor mínimo da função é  $f(x, y=1) = 0.0010579884374510775$

### Conclusão

Apesar da função de Rosenbrock poder ser avaliada em dois domínios distintos, os resultados melhores foram encontrados no domínio mais restrito. Como são menos valores a serem analisados, fica mais fácil encontrar os pontos dos extremos e o valor do mínimo ser próximo do esperado. Os resultados ficam nitidamente visíveis quando os gráficos e os dados estatísticos são comparados. Para o domínio mais restrito, os valores da média, mediana e desvio padrão foram menores e mais satisfatórios.

Seria possível obter mais resultados pela análise da função com mais dimensões e testar a sua forma modificada de Picheny, com  $d = 4$ .

### Referências

Rosenbrock Function. Disponível em: <https://www.sfu.ca/~ssurjano/rosen.html>. Acesso em: 30 oct 2024.